

Clima e dengue nas 27 capitais brasileiras: associações não lineares e valor preditivo incremental em validação temporal retrospectiva, 2021–2025

Manuscrito anônimo para avaliação. Artigo original.

Resumo

Relações climáticas com dengue são biologicamente plausíveis, mas associação não implica utilidade preditiva depois de considerada a memória recente da transmissão. Investigamos associações não lineares e defasadas e o valor preditivo incremental de temperatura, umidade e precipitação nas 27 capitais brasileiras. Construímos painel semanal do InfoDengue e NASA POWER, 2021–2025. Antes de estimar modelos, congelamos hipóteses, código e dados por SHA-256. Para 2021–2024, ajustamos regressão quasi-Poisson com efeitos fixos capital×mês e ano, bases cruzadas climáticas e bootstrap de escores em blocos calendários. Em 2025, comparamos retrospectivamente um baseline autorregressivo a um modelo acrescido de clima, ambos com origem em $t-1$. A análise associacional incluiu 5.079 capital-semanas. Para temperatura no percentil 75 versus 25, lags 3–8, a razão de taxas foi 0,833 (IC95%: 0,333–1,956), tornando a primeira hipótese inconclusiva. A relação foi não linear ($p=2,63\times 10^{-39}$), mas o contraste de inclinações acima versus abaixo do percentil 75 foi positivo (0,669 log[razão de taxas]/°C; IC95%: 0,274–1,064), direção oposta à saturação pré-especificada. No holdout completo de 2025 (1.431 capital-semanas), a melhora do desvio de Poisson foi -5,69% (IC95%: -19,07% a 4,64%), embora 18 capitais tenham melhorado; a hipótese preditiva permaneceu inconclusiva. Um controle negativo com exposições climáticas futuras foi significativo, resultado compatível com estrutura temporal residual. Assim, a forma comum de saturação térmica pré-especificada para o painel não se sustentou, e não demonstramos ganho preditivo nacional consistente. Não linearidade, variação espacial exploratória e controle temporal insuficiente devem ser considerados antes de atribuir mecanismo ou transportabilidade a modelos clima–dengue.

Palavras-chave: Dengue; Temperatura; Análise de Séries Temporais; Previsão; Brasil.

Introdução

A dengue resulta de interações entre vírus, vetores, hospedeiros, ambiente e capacidade de vigilância. Temperatura afeta sobrevivência, desenvolvimento e competência vetorial de *Aedes*, mas esses processos operam em faixas térmicas e escalas temporais distintas. Limites de persistência e competência variam entre espécies e contextos ¹; flutuações diárias podem alterar a transmissão mesmo sob a mesma média térmica ²; e modelos mecanísticos sugerem curvas unimodais, com aumento de adequação até um intervalo ótimo e redução em temperaturas mais altas ³. Revisões

sobre *Aedes* reforçam a multiplicidade desses mecanismos ⁴, enquanto projeções climáticas mostram redistribuição geográfica, e não simples expansão uniforme, do risco ⁵. A temperatura também modifica o intervalo de geração da dengue ⁶. Meta-análise recente encontrou associação entre calor e dengue, mas destacou heterogeneidade substancial entre zonas climáticas e desenhos ⁷.

Modelos de defasagem distribuída não linear permitem representar simultaneamente a forma da exposição-resposta e a distribuição temporal da associação ⁸, com implementação e interpretação consolidadas ⁹ e métodos para sintetizar curvas entre localidades ¹⁰. Aplicações em Barbados ¹¹, Singapura ¹², Índia ¹³, Tailândia ¹⁴ e Laos ¹⁵ documentaram relações temporais entre temperatura, umidade ou chuva e dengue. No Brasil, estudos semanais em São Paulo e Natal ¹⁶ e uma análise nacional de hospitalizações ¹⁷ estimaram relações térmicas não lineares e defasadas; um estudo mensal em Belo Horizonte associou temperatura e umidade à incidência ¹⁸. As unidades, os desfechos e os controles diferiram. Esse conjunto sustenta a plausibilidade de uma relação climática, mas não define uma curva universal nem garante identificação mecanística em painéis ecológicos.

Previsão é uma pergunta diferente de associação. Desafios abertos de dengue mostraram que avaliação fora da amostra, calibração e comparação com baselines fortes são indispensáveis ¹⁹. Modelos que combinam vigilância, clima e variáveis socioeconômicas podem perder desempenho fora da amostra ²⁰, e previsões semanais em diferentes locais evidenciam variação na contribuição do clima ²¹. Superensembles sazonais foram usados para combinar e calibrar previsões ²², porém trabalham com horizontes distintos do alerta semanal. No Brasil, foram propostos modelos com preditores derivados de temperatura e umidade ²³, comparações estatísticas e de aprendizado de máquina no Rio de Janeiro ²⁴, avaliações de curto prazo nas capitais ²⁵ e iniciativas operacionais de previsão probabilística ²⁶. Estudos recentes também converteram estruturas de defasagem em preditores ²⁷. Ainda assim, permanece pouco testado se o clima melhora, em escala nacional harmonizada, uma previsão semanal que já conhece os casos recentes.

O InfoDengue integra notificações e componentes de vigilância em séries semanais ²⁸. Modelos climáticos em diferentes regiões brasileiras ²⁹ e análises com dados heterogêneos ³⁰ mostram variação espacial relevante. Novos conjuntos geoespaciais ampliaram a infraestrutura de dados ³¹, enquanto estratificações epidêmico-climáticas documentaram variabilidade regional ³²; a plataforma Mosqlimate favorece acesso e comparação reprodutível de previsões ³³. Estudos em cidades brasileiras combinaram casos com sinais digitais ³⁴ ou detalharam dinâmicas em Porto Alegre ³⁵. Em Cadernos de Saúde Pública, uma análise de séries temporais de Minas Gerais mostrou elevada heterogeneidade da relação temperatura-dengue entre microrregiões ³⁶.

Nosso objetivo foi testar, sob protocolo congelado, três hipóteses falsificáveis nas 27 capitais: (H1) temperaturas no percentil 75, comparadas ao percentil 25, estariam associadas a maior incidência acumulada de dengue nos lags 3–8; (H2) a inclinação da curva diminuiria acima do percentil 75, compatível com saturação ou reversão em calor mais intenso; e (H3) acrescentar clima a um baseline de casos recentes melhoraria em pelo menos 5% o desvio de Poisson em 2025, com intervalo

inteiramente positivo e melhora em ao menos 16 capitais. A análise separou associação e previsão, incluiu controle negativo com exposições futuras e tratou resultados adversos como informação científica.

Métodos

Desenho, unidades e período

Realizamos estudo ecológico longitudinal com unidade capital-semana epidemiológica. Incluímos as 26 capitais estaduais e Brasília, de 3 de janeiro de 2021 a 3 de janeiro de 2026, abrangendo as semanas epidemiológicas de 2021–2025. O período 2021–2024 foi reservado ao modelo associacional e ao treinamento preditivo; 2025 foi mantido como holdout temporal. Nenhuma observação de 2025 participou do ajuste associacional, da escolha de nós ou da estimação de transformações.

Fontes e aquisição

Obtivemos, em 30 de agosto de 2026, um snapshot por capital da API pública InfoDengue (<https://info.dengue.mat.br/api/alertcity>), doença dengue, semanas 1–53 e anos 2021–2025. Extraímos casos notificados, casos estimados, população, temperatura média, umidade média, início da semana e versão do modelo. Validamos códigos, nomes e unidades federativas contra a API de Localidades do Instituto Brasileiro de Geografia e Estatística (IBGE). O schema vivo continha 31 campos e foi fixado por fingerprint SHA-256; respostas brutas, URL, horário, MIME, tamanho e checksum foram preservados.

Como o endpoint auditado não fornecia precipitação, consultamos a API diária NASA POWER, parâmetro PRECTOTCORR, fonte MERRA-2, nas coordenadas das capitais publicadas pelo IBGE. Para cada semana, somamos os sete dias de domingo a sábado. A consulta se estendeu até 3 de janeiro de 2026 para completar a semana 53 de 2025. Exigimos 1.827 dias por capital, ausência de fill -999, valores não negativos, sete dias por semana e correspondência exata às 261 semanas.

Desfechos, exposições e preparação

O desfecho primário foi a contagem semanal de casos notificados; $\log(\text{população})$ foi o offset. Casos estimados constituíram sensibilidade planejada. A exposição primária foi temperatura média semanal, com umidade média como ajuste meteorológico e precipitação semanal como controle. Não usamos R_t , nível de alerta, receptividade ou transmissão como preditores, pois são derivados do próprio sistema e poderiam incorporar o desfecho.

Ordenamos semanas dentro de capital e geramos defasagens sem atravessar unidades. A análise primária utilizou casos completos; não imputamos o desfecho. Exigimos grade bruta única e contínua de 27×52 semanas em cada ano de 2021–2024 e 27×53 em 2025, com mapeamento único semana-

data. Todas as capitais deveriam permanecer depois dos casos completos. Interpolação linear foi reservada à sensibilidade de lacunas meteorológicas internas de até duas semanas.

Modelo associacional e hipóteses H1-H2

Ajustamos regressão de Poisson para a média, com dispersão de Pearson estimada separadamente, offset populacional, efeitos fixos para cada combinação capital×mês do ano e efeitos de ano. A base cruzada de temperatura combinou spline cúbica natural de exposição com quatro graus de liberdade, nós nos percentis 25, 50 e 75 do treino, e spline natural de lag com três graus de liberdade nos lags 0–8. Para umidade, usamos spline natural de exposição com três graus de liberdade e nós nos tercís, cruzada com intercepto e tendência linear do lag 0–8. A precipitação entrou por log1p de duas somas: lags 0–2 e 3–8.

H1 comparou cumulativamente o percentil 75 ao percentil 25 da temperatura nos lags 3–8, com alternativa unilateral razão de taxas maior que 1. H2 comparou a variação de log(razão de taxas) por grau entre P95–P75 e P75–P25, esperando contraste negativo; exigiu também evidência de não linearidade pelo teste assintótico da diferença de deviance escalada entre o desenho completo e uma alternativa linear aninhada. O p composto de H2 foi o maior dos dois p unilaterais/estruturais. Aplicamos Holm a H1–H2 em 5%.

Estimamos incerteza primária por bootstrap one-step dos escores, 1.999 réplicas, blocos móveis de oito semanas e as mesmas semanas em todas as capitais. Antes do ajuste, exigimos posto completo dos desenhos não linear e linear, aninhamento numérico e diferença de posto igual a nove. Números de condição e valores singulares foram registrados. Os intervalos são percentis dos draws do bootstrap; a dispersão extrema não foi tratada com erros-padrão ingênuos do Poisson.

Validação preditiva retrospectiva e H3

Previmos casos da semana t com informação fechada em $t-1$. O baseline continha efeitos de capital, três pares de termos harmônicos anuais e log1p(casos) nos lags 1–4. O modelo climático acrescentou bases cruzadas de temperatura e umidade somente nos lags 1–8 e log1p da precipitação acumulada nos lags 1–2 e 3–8. Nós e transformações foram ajustados apenas em 2021–2024; os dois modelos foram avaliados nas mesmas 1.431 observações de 2025.

A métrica primária foi a média do desvio de Poisson. Calculamos melhora percentual como $100 \times (\text{desvio baseline} - \text{desvio climático}) / \text{desvio baseline}$; valores positivos favorecem o clima. Também calculamos erro absoluto médio, correlação de Spearman, calibração por decis e cobertura de um intervalo aproximado de observação quase-Poisson. A incerteza da melhora usou 1.999 réplicas em blocos móveis de quatro semanas comuns às capitais. H3 exigiu simultaneamente melhora mínima de 5%, limite inferior do IC95% acima de zero e melhora em pelo menos 16 das 27 capitais.

O snapshot corrente do InfoDengue contém revisões posteriores às origens históricas. Portanto, a avaliação mede valor preditivo incremental retrospectivo sob snapshot fixo; não representa previsão prospectiva, vintage em tempo real ou desempenho operacional histórico.

Sensibilidades e controles negativos

Reestimamos associação com casos estimados, sem chuva, agrupamento alternativo da chuva, exclusão de 2024, lags 0–4 e 0–12 e interpolação curta; cada uma usou 499 réplicas. Ajustamos binomial negativa por momentos e, como diagnóstico, GEE Poisson exchangeable dentro de capital. Avaliamos estimativas por macrorregião e leave-one-capital-out com base fixa. Para predição, repetimos casos estimados, ausência/agrupamento alternativo de chuva e exclusão de 2024.

Como controle negativo de exposição, acrescentamos temperatura e umidade futuras nos leads 1–4 ao modelo associacional. Associação com exposições posteriores à semana-alvo sinaliza autocorrelação meteorológica, sazonalidade ou confundimento temporal residual. Também permutamos 199 vezes o vetor térmico completo de lags dentro de capital×ano×mês. Sensibilidades não puderam alterar decisões confirmatórias.

Reprodutibilidade, ética e uso de inteligência artificial

O protocolo, código, parâmetros, seeds e relatórios de qualidade foram congelados por SHA-256 após autorização teórica final e antes de qualquer estimação. A suíte prospectiva teve 43 testes; os resultados finais foram inventariados com hashes. Utilizamos Python 3.12.13, numpy 2.5.2, pandas 2.3.3, scipy 1.18.1 e statsmodels 0.15.0.

Foram usados exclusivamente dados públicos, agregados por capital e semana, sem identificadores individuais; não houve contato com participantes. Esta versão foi gerada integralmente com sistemas de IA da OpenAI: ChatGPT Pro atuou na formulação teórica e nas decisões finais; Codex executou busca bibliográfica, aquisição, programação, auditorias, análise e redação. Nenhum sistema de IA é autor. A submissão exige revisão independente e assunção explícita de responsabilidade por autores humanos, conforme as políticas editoriais.

Resultados

Cobertura e descrição

O painel bruto reuniu 7.047 capital-semanas: 52 semanas por capital em 2021–2024 e 53 em 2025. Houve 4.189.585 casos notificados. O pico ocorreu em 2024, com 2.459.955 casos e incidência média semanal de 59,2 por 100 mil, seguido de redução em 2025 (694.616 casos; 23,9 por 100 mil) (Tabela 1; Figura 1). Temperatura mediana semanal variou pouco entre anos, enquanto precipitação e epidemias mostraram ciclos e amplitudes distintas.

Tabela 1. Descrição anual do painel das 27 capitais brasileiras, 2021–2025.

Ano	Capital-semanas	Casos	Incidência média/100 mil	Temp. mediana (°C)	Umidade mediana (%)	Chuva mediana (mm/sem.)
2.021	1.404	167.668	9,0	25,7	76,5	17,6
2.022	1.404	407.696	23,0	25,3	78,4	19,8
2.023	1.404	459.650	27,8	25,7	78,4	14,7
2.024	1.404	2.459.955	59,2	26,2	77,8	13,4
2.025	1.431	694.616	23,9	25,6	78,6	13,7

Incidência é a média das taxas capital-semana; temperatura, umidade e precipitação são medianas das capital-semanas.




Figura 1. Séries semanais de incidência notificada, temperatura média e precipitação média nas 27 capitais, 2021–2025. Incidência é a taxa agregada — total de casos dividido pela população somada — por 100 mil habitantes; temperatura e precipitação são médias semanais entre capitais.

As 49.329 observações diárias de precipitação passaram integralmente nos gates. Temperatura ou umidade estavam ausentes em 187/7.047 linhas (2,65%), concentradas em Teresina (129). As janelas de lag reduziram a amostra associacional de 5.616 para 5.079 linhas; todas as 27 capitais permaneceram, mas Teresina contribuiu 69 de 208 semanas. O desenho completo teve posto

347/347, o linear 338/338 e o concatenado 347; o número de condição do desenho completo foi 3.275. A dispersão de Pearson foi 303,85.

Hipóteses associacionais

Para H1, P75 foi 27,17°C e P25 23,06°C. A razão de taxas cumulativa P75/P25 nos lags 3–8 foi 0,833 (IC95%: 0,333–1,956; p unilateral=0,656; p de Holm=1,000); a hipótese de aumento permaneceu inconclusiva (Tabela 2).

Tabela 2. Resultados e decisões das hipóteses pré-especificadas.

Hipótese	Estimativa	IC95%	Regra confirmatória	Decisão
H1	RT=0,833	0,333 a 1,956	RT P75/P25 >1; Holm 5%	Inconclusiva
H2	0,669 log(RT)/°C	0,274 a 1,064	Contraste <0 e não linearidade	Refutada na direção
H3	-5,69%	-19,07% a 4,64%	≥5%; IC>0; ≥16 capitais	Inconclusiva

RT: razão de taxas. H1–H2: bootstrap de escores em blocos, 1.999 réplicas; H3: bootstrap calendárico, 1.999 réplicas. A refutação de H2 diz respeito apenas à direção formulada.

Na especificação primária, o teste indicou não linearidade (diferença de deviance escalada=205,24; 9 gl; $p=2,63 \times 10^{-39}$). Entretanto, o contraste entre a inclinação P95–P75 e P75–P25 foi +0,669 log(razão de taxas)/°C (IC95%: +0,274 a +1,064), inteiramente na direção oposta à saturação esperada. O p composto e o p ajustado pelo método de Holm para a direção originalmente esperada foram ambos 1,000. Portanto, H2 foi refutada quanto à direção pré-especificada, sem que isso implique mecanismo biológico oposto. A curva térmica e os efeitos específicos por lag foram imprecisos nos extremos (Figura 2). A associação exploratória da umidade aumentou acentuadamente em valores altos, igualmente sujeita aos diagnósticos temporais.




Figura 2. Associações climáticas ajustadas no modelo primário, 2021–2024. A–B: curvas cumulativas de temperatura, referência P25=23,06°C; C: RT P75/P25 por lag; D: curva exploratória de umidade, referência P25=71,05%. Faixas: IC95% do bootstrap de escores em blocos.

H1 permaneceu inconclusiva nas especificações planejadas: as razões de taxas variaram de 0,714, sem chuva, a 1,024, em lags 0–12. O contraste de H2 permaneceu positivo, com IC95% acima de zero, e a não linearidade teve $p < 10^{-30}$ em todas as reestimações. No leave-one-capital-out, H1 variou de 0,655 a 1,314 e ficou abaixo de 1 em 24 das 27 omissões. A binomial negativa convergiu e produziu $H1=0,858$ (IC model-based: 0,803–0,916), não diretamente comparável ao bootstrap primário. A GEE exchangeable não convergiu e suas estimativas foram não calculáveis. Casos estimados e notificados foram numericamente idênticos nas 7.047 linhas, tornando essa sensibilidade não independente.

O controle negativo com clima futuro rejeitou a hipótese conjunta de ausência dos 18 termos de leads 1–4 (deviance escalada=513,53; 18 gl; $p=1,49 \times 10^{-97}$). O contraste térmico futuro P75/P25 foi 1,453 (IC95%: 0,659–2,734). A permutação térmica dentro de estratos produziu p unilateral=0,32 para H1. A falha do controle negativo impede atribuir com segurança a associação observada a uma janela biologicamente específica.

Validação temporal retrospectiva

O holdout de 2025 permaneceu completo: 1.431/1.431 capital-semanas. O desvio médio de Poisson foi 14,082 no baseline e 14,883 no modelo climático, melhora de -5,69% (IC95%: -19,07% a +4,64%). O erro absoluto médio aumentou de 60,68 para 67,10 casos; Spearman foi 0,9678 e 0,9667, respectivamente. H3 ficou inconclusiva (Tabela 2).

Apesar da piora agregada, o clima reduziu o desvio em 18 capitais. As maiores melhoras ocorreram em Natal (+22,2%), Recife (+21,0%), Manaus (+18,4%) e Goiânia (+18,0%); as maiores pioras, em Teresina (-88,8%) e São Paulo (-26,6%). A trajetória agregada foi semelhante entre modelos, mas as mudanças por capital foram assimétricas (Figura 3). Sem chuva, a melhora foi -2,42% (IC95%: -14,04% a +6,82%); com janelas alternativas de chuva, -6,32% (-21,23% a +4,25%); excluindo 2024 do treino, +6,04% (-2,71% a +11,71%), com melhora em apenas 15 capitais. Nenhuma sensibilidade satisfaz a regra conjunta.




Figura 3. Validação temporal retrospectiva de 2025. A: casos observados e previstos agregados nas 27 capitais; B: melhora percentual do desvio de Poisson por capital, com valores positivos favorecendo o modelo climático. Resultados por capital são exploratórios.

Discussão

Achados principais

Sob hipóteses e código congelados prospectivamente, não confirmamos maior incidência acumulada no P75 versus P25 de temperatura nos lags 3-8. Houve forte evidência estatística de não linearidade

sob o modelo, porém a desaceleração esperada acima do P75 foi refutada quanto à direção; o contraste permaneceu positivo nas reestimações quasi-Poisson planejadas. Esse resultado não demonstra intensificação biológica pelo calor, porque o controle negativo com exposições futuras foi fortemente significativo. Na validação retrospectiva de 2025, acrescentar clima não demonstrou ganho agregado sobre um baseline que já incorporava casos recentes; frequência e magnitude divergiram, pois 18 capitais melhoraram enquanto o desempenho nacional piorou.

A ausência de suporte para H1 não equivale a ausência de associação climática. A literatura mecanística prevê dependência térmica de múltiplos componentes, curvas não monotônicas e efeitos de flutuação ^{1-4,6}. Projeções apontam redistribuição geográfica do risco ⁵, e meta-análise epidemiológica documenta heterogeneidade entre zonas climáticas e desenhos ⁷. Estudos com DLNM em Barbados, Singapura, Índia e Laos encontraram formas e lags variados ^{11-13,15}; uma análise provincial tailandesa também identificou associações climáticas defasadas e avaliou desempenho em um ano de teste ¹⁴. Estudos brasileiros em unidades, desfechos e escalas distintas produziram estimativas heterogêneas e, em conjunto, não justificam transportar um único limiar ^{16-18,36}. Nosso contraste P75/P25 foi definido no painel combinado e testou uma hipótese nacional específica; a ampla incerteza e a variação regional mostram por que não deve ser generalizado como resposta biológica de cada capital.

H2 exige distinção ainda mais cuidadosa. O IC inteiramente positivo refuta a direção negativa pré-especificada, mas a significância de leads futuros mostra que o modelo associa dengue a componentes climáticos que não respeitam a precedência temporal esperada. Como temperatura e umidade são autocorrelacionadas e sazonais, exposições futuras podem funcionar como proxies de estados meteorológicos persistentes. Também podem restar estrutura epidêmica, imunidade, sorotipos, mobilidade, controle vetorial e mudanças de vigilância. Assim, a curva descreve uma associação ajustada dentro deste painel; não identifica uma janela causal nem comprova mecanismo oposto à saturação.

Associação versus previsão

O resultado preditivo reforça que significância associacional e utilidade fora da amostra são propriedades diferentes. Competições e aplicações anteriores recomendam baselines fortes e validação temporal ¹⁹⁻²². Depois de incluir quatro lags de casos e sazonalidade, o clima não atingiu a melhora mínima, e o IC excluiu ganhos acima de 4,64% na especificação primária. Não se conclui que clima nunca ajude: houve melhora em 18 capitais. Aplicações brasileiras mostram abordagens locais, multicidade e de ensemble ^{23-26,34,35}, enquanto o estudo de Hainan ilustra a incorporação de estruturas de defasagem em validação temporal ²⁷. A plataforma Mosqlimate apoia a comparação reprodutível de modelos ³³. Modelos hierárquicos com agrupamento parcial permanecem uma proposta para explorar essa heterogeneidade; o que não foi demonstrado foi um benefício nacional consistente desta parametrização comum.

O contraste entre 18 melhoras e piora agregada é substantivo. Capitais com pequenos ganhos foram superadas por deteriorações maiores em algumas unidades. Teresina teve pouca informação climática no treino, embora o holdout estivesse completo; São Paulo concentrou epidemias de grande amplitude. Estimativas por capital não foram submetidas a inferência confirmatória nem ajuste de multiplicidade. Portanto, rankings devem orientar novas hipóteses, não decisões locais imediatas.

Forças e limitações

Entre as forças estão cobertura das 27 capitais, aquisição auditável de duas fontes públicas, grade semanal comum, separação estrita entre treino e holdout, prevenção programática de vazamento e congelamento por hash antes dos resultados. Hipóteses incluíram critérios de confirmação e refutação; resultados negativos, GEE não convergente, sensibilidade não informativa e controle negativo adverso foram preservados. O bootstrap reamostrou semanas comuns às capitais, respeitando dependência contemporânea, e a suíte de robustez não pôde substituir a análise confirmatória.

Há limitações importantes. Primeiro, o desenho ecológico não controla completamente imunidade, sorotipos, infestação vetorial, intervenções, mobilidade, condições sociais ou mudanças diagnósticas. Segundo, a dispersão de Pearson foi extrema; embora o bootstrap em blocos seja preferível aos erros ingênuos, a inferência permanece sensível à estrutura de dependência. Terceiro, a GEE com apenas 27 clusters não convergiu, eliminando um diagnóstico alternativo. Quarto, perdas climáticas foram geograficamente concentradas, sobretudo em Teresina; a interpolação curta não recupera ausências prolongadas. Quinto, pontos gridded de NASA POWER e médias do InfoDengue não representam microclimas intraurbanos.

Sexto, o controle negativo de leads falhou. Isso não invalida a descrição associacional nem a comparação preditiva, mas é uma limitação central à temporalidade e impede linguagem causal, mecanística ou de efeito tardio. Sétimo, o holdout cobre um único ano depois da epidemia excepcional de 2024. O snapshot do InfoDengue foi revisado retrospectivamente; lags de casos podem conter atualizações feitas depois da origem histórica. A avaliação não reproduz a informação disponível em tempo real. O campo de casos estimados coincidiu integralmente com casos, não constituindo validação independente.

Finalmente, o modelo impôs uma superfície climática comum com efeitos fixos de capital, enquanto a literatura e nossos resultados exploratórios apontam heterogeneidade^{29,30,32,35,36}. Modelos hierárquicos com curvas parcialmente agrupadas, múltiplos vintages e validação rolling-origin em vários anos são extensões prioritárias. Deveriam registrar previsões antes da observação dos desfechos, comparar calibração probabilística e testar controles negativos adicionais.

Conclusão

Nas 27 capitais brasileiras, a hipótese de maior incidência acumulada de dengue no P75 versus P25 térmico nos lags 3–8 permaneceu inconclusiva, e a saturação acima do P75 foi refutada na direção pré-especificada. O clima não demonstrou ganho preditivo agregado confirmatório em 2025 sobre a memória recente dos casos, embora tenha melhorado parte das capitais. A associação não linear, a substancial variação espacial exploratória e o placebo com clima futuro mostram que relações estatísticas clima–dengue não devem ser convertidas automaticamente em mecanismo térmico ou alerta transportável. Modelos locais ou hierárquicos, avaliados prospectivamente e com vintages históricos, são necessários antes de uso operacional.

Disponibilidade de dados e materiais

As séries de origem são acessíveis pelas APIs públicas InfoDengue e NASA POWER; códigos municipais e coordenadas foram validados em fontes do IBGE. URLs, parâmetros, horários, schemas e SHA-256 integram o pacote reproduzível desta versão. Código, protocolo congelado, manifestos, tabelas e figuras acompanham o manuscrito. A redistribuição pública dos payloads brutos deve observar os termos dos mantenedores; a API InfoDengue não apresentava licença explícita na data de acesso.

Declarações

Informações de autoria, contribuições humanas, financiamento e conflitos de interesse não foram fornecidas e, por isso, não são declaradas nesta versão anônima. Antes de submissão, autores humanos devem revisar independentemente texto, código, dados e referências, fornecer essas declarações e assumir responsabilidade integral. O uso de IA está descrito em Métodos e não implica autoria.

Referências

1. Brady OJ, Golding N, Pigott DM, Kraemer MUG, Messina JP, Reiner RC Jr, et al. Global temperature constraints on *Aedes aegypti* and *Ae. albopictus* persistence and competence for dengue virus transmission. *Parasites & Vectors*. 2014;7(1):338. doi: 10.1186/1756-3305-7-338.
2. Carrington LB, Armijos MV, Lambrechts L, Scott TW. Fluctuations at a Low Mean Temperature Accelerate Dengue Virus Transmission by *Aedes aegypti*. *PLOS Neglected Tropical Diseases*. 2013;7(4):e2190. doi: 10.1371/journal.pntd.0002190.
3. Mordecai EA, Cohen JM, Evans MV, Gudapati P, Johnson LR, Lippi CA, et al. Detecting the impact of temperature on transmission of Zika, dengue, and chikungunya using mechanistic models. *PLOS Neglected Tropical Diseases*. 2017;11(4):e0005568. doi: 10.1371/journal.pntd.0005568.
4. Reinhold J, Lazzari C, Lahondère C. Effects of the Environmental Temperature on *Aedes aegypti* and *Aedes albopictus* Mosquitoes: A Review. *Insects*. 2018;9(4):158. doi: 10.3390/insects9040158.
5. Ryan SJ, Carlson CJ, Mordecai EA, Johnson LR. Global expansion and redistribution of *Aedes*-borne virus transmission risk with climate change. *PLOS Neglected Tropical Diseases*. 2019;13(3):e0007213. doi: 10.1371/journal.pntd.0007213.

6. Codeço CT, Villela DAM, Coelho FC. Estimating the effective reproduction number of dengue considering temperature-dependent generation intervals. *Epidemics*. 2018;25:101-111. doi: 10.1016/j.epidem.2018.05.011.
7. Damtew YT, Tong M, Varghese BM, Anikeeva O, Hansen A, Dear K, et al. Effects of high temperatures and heatwaves on dengue fever: a systematic review and meta-analysis. *eBioMedicine*. 2023;91:104582. doi: 10.1016/j.ebiom.2023.104582.
8. Gasparrini A, Armstrong B, Kenward MG. Distributed lag non-linear models. *Statistics in Medicine*. 2010;29(21):2224-2234. doi: 10.1002/sim.3940.
9. Gasparrini A. Distributed Lag Linear and Non-Linear Models in R: The Package dlnm. *Journal of Statistical Software*. 2011;43(8):1-20. doi: 10.18637/jss.v043.i08.
10. Gasparrini A, Armstrong B. Reducing and meta-analysing estimates from distributed lag non-linear models. *BMC Medical Research Methodology*. 2013;13(1):1. doi: 10.1186/1471-2288-13-1.
11. Lowe R, Gasparrini A, Van Meerbeeck CJ, Lippi CA, Mahon R, Trotman AR, et al. Nonlinear and delayed impacts of climate on dengue risk in Barbados: A modelling study. *PLOS Medicine*. 2018;15(7):e1002613. doi: 10.1371/journal.pmed.1002613.
12. Xu HY, Fu X, Lee LKH, Ma S, Goh KT, Wong J, et al. Statistical Modeling Reveals the Effect of Absolute Humidity on Dengue in Singapore. *PLOS Neglected Tropical Diseases*. 2014;8(5):e2805. doi: 10.1371/journal.pntd.0002805.
13. Kakarla SG, Caminade C, Mutheneni SR, Morse AP, Upadhyayula SM, Kadiri MR, et al. Lag effect of climatic variables on dengue burden in India. *Epidemiology and Infection*. 2019;147:e170. doi: 10.1017/s0950268819000608.
14. Chumpu R, Khamsemanan N, Nattee C. The association between dengue incidences and provincial-level weather variables in Thailand from 2001 to 2014. *PLOS ONE*. 2019;14(12):e0226945. doi: 10.1371/journal.pone.0226945.
15. Sugeno M, Kawazu EC, Kim H, Banouvong V, Pehlivan N, Gilfillan D, et al. Association between environmental factors and dengue incidence in Lao People's Democratic Republic: a nationwide time-series study. *BMC Public Health*. 2023;23(1):2348. doi: 10.1186/s12889-023-17277-0.
16. Lorenz C, Ynoue RY, Gioda A, Nogueira T. Influence of climate and heatwaves on dengue transmission in Sao Paulo and Natal, Brazil. *PLOS ONE*. 2025;20(10):e0334838. doi: 10.1371/journal.pone.0334838.
17. Lopes R, Basagaña X, Bastos LSL, Bozza FA, Ranzani OT. Ambient temperature and dengue hospitalization in Brazil: A 10-year period case time series analysis. *Environmental Epidemiology*. 2024;9(1):e360. doi: 10.1097/ee9.0000000000000360.
18. Ribeiro SP, Cruz TC, Vieira-Duarte R, Monteiro JCL, Veloso GA, Silva MC, et al. Impact of temperature on the incidence of dengue fever in an endemic urban area. *Discover Public Health*. 2025;22(1):816. doi: 10.1186/s12982-025-01218-w.
19. Johansson MA, Apfeldorf KM, Dobson S, Devita J, Buczak AL, Baugher B, et al. An open challenge to advance probabilistic forecasting for dengue epidemics. *Proceedings of the National Academy of Sciences*. 2019;116(48):24268-24274. doi: 10.1073/pnas.1909865116.
20. Jain R, Sontisirikit S, Iamsirithaworn S, Prendinger H. Prediction of dengue outbreaks based on disease surveillance, meteorological and socio-economic data. *BMC Infectious Diseases*. 2019;19(1):272. doi: 10.1186/s12879-019-3874-x.
21. Benedum CM, Shea KM, Jenkins HE, Kim LY, Markuzon N. Weekly dengue forecasts in Iquitos, Peru; San Juan, Puerto Rico; and Singapore. *PLOS Neglected Tropical Diseases*. 2020;14(10):e0008710. doi: 10.1371/journal.pntd.0008710.
22. Colón-González FJ, Soares Bastos L, Hofmann B, Hopkin A, Harpham Q, Crocker T, et al. Probabilistic seasonal dengue forecasting in Vietnam: A modelling study using superensembles. *PLOS Medicine*. 2021;18(3):e1003542. doi: 10.1371/journal.pmed.1003542.
23. Li Z. Forecasting Weekly Dengue Cases by Integrating Google Earth Engine-Based Risk Predictor Generation and Google Colab-Based Deep Learning Modeling in Fortaleza and the Federal District, Brazil. *International Journal of Environmental Research and Public Health*. 2022;19(20):13555. doi: 10.3390/ijerph192013555.
24. Chen X, Moraga P. Assessing dengue forecasting methods: a comparative study of statistical models and machine learning techniques in Rio de Janeiro, Brazil. *Tropical Medicine and Health*. 2025;53(1):52. doi: 10.1186/s41182-025-00723-7.
25. Silva DCDCE, Nery LM, Nicomedes NDP, Camargo PCMDG, Lusquino Filho LAD, Costa RDVFD, et al. Comparative evaluation of machine learning strategies for short-term dengue forecasting in Brazilian capital municipalities. *International Journal of Biometeorology*. 2026;70(8):233. doi: 10.1007/s00484-026-03300-7.
26. Araujo EC, Carvalho LM, Ganem F, Vacaro LB, Bastos LS, Freitas LP, et al. Leveraging probabilistic forecasts for dengue preparedness and control: The 2024 Dengue Forecasting Sprint in Brazil. *Proceedings of the National Academy of Sciences*. 2026;123(7):e2508989123. doi: 10.1073/pnas.2508989123.
27. Lian Y, Jin Y, Wang Y, Qiu L, Chen J, Guo Y, et al. Meteorological drivers and short-term prediction of dengue fever in a tropical region of China: evidence from Hainan Province. *Frontiers in Public Health*. 2026;14:1919479. doi: 10.3389/fpubh.2026.1919479.

28. Codeço CT, Cruz OG, Riback TI, Degener CM, Gomes MF, Villela D, et al. InfoDengue: a nowcasting system for the surveillance of dengue fever transmission [preprint]. *bioRxiv*. 2016. doi: 10.1101/046193.
29. Alves LD, Lana RM, Coelho FC. A Framework for Weather-Driven Dengue Virus Transmission Dynamics in Different Brazilian Regions. *International Journal of Environmental Research and Public Health*. 2021;18(18):9493. doi: 10.3390/ijerph18189493.
30. Castro LA, Generous N, Luo W, Pastore y Piontti A, Martinez K, Gomes MFC, et al. Using heterogeneous data to identify signatures of dengue outbreaks at fine spatio-temporal scales across Brazil. *PLOS Neglected Tropical Diseases*. 2021;15(5):e0009392. doi: 10.1371/journal.pntd.0009392.
31. Zhu Q, Li Z, Dong J, Fu P, Cheng Q, Cai J, et al. Spatiotemporal dataset of dengue influencing factors in Brazil based on geospatial big data cloud computing. *Scientific Data*. 2025;12(1):712. doi: 10.1038/s41597-025-05045-1.
32. Gouveia AS, Gomes MFDC, de Almeida IF, Lana RM, Bastos LS, Bianchi LM, et al. Unraveling regional variability in Dengue outbreaks in Brazil: leveraging the Moving Epidemics Method (MEM) and climate data to optimize vector control strategies. *PLOS Neglected Tropical Diseases*. 2025;19(6):e0013175. doi: 10.1371/journal.pntd.0013175.
33. Ganem F, Vacaro LB, Araújo EC, Alves LD, Bastos LS, Carvalho LM, et al. Mosqlimate: a platform to providing automatable access to data and forecasting models for arbovirus disease [preprint]. *arXiv*. 2024. doi: 10.48550/arxiv.2410.18945.
34. Koplewitz G, Lu F, Clemente L, Buckee C, Santillana M. Predicting dengue incidence leveraging internet-based data sources. A case study in 20 cities in Brazil. *PLOS Neglected Tropical Diseases*. 2022;16(1):e0010071. doi: 10.1371/journal.pntd.0010071.
35. da Silva AA, Ferreira ÁGA, Lourenço J, Cupertino de Freitas A. Climate-driven spatiotemporal dynamics of Aedes infestation and dengue transmission in Porto Alegre, Southern Brazil. *PLOS Neglected Tropical Diseases*. 2026;20(8):e0014201. doi: 10.1371/journal.pntd.0014201.
36. Gomes JPM, Ribas IM, Valadares PAR, Jardim LS, Nogueira MC, Ferreira CDCM, et al. Relação entre temperatura do ar e incidência de dengue: estudo de séries temporais em Minas Gerais, Brasil (2010-2019). *Cadernos de Saúde Pública*. 2024;40(3):e00076723. doi: 10.1590/0102-311xpt076723.