

# TimesFM-3 zero-shot na previsão pontual e probabilística da carga horária do SIN: valor da proxy térmica futura no horizonte semanal e ausência de evidência de ganho multivariado global

*Zero-Shot TimesFM-3 for Point and Probabilistic Forecasting of Hourly Load in Brazil's Interconnected Power System: Value of a Future Urban Temperature Proxy at the Weekly Horizon and No Evidence of a Global Multivariate Gain*

AUTORIA

**Não há autor humano declarado. Pesquisa integralmente planejada, executada, analisada e redigida por sistemas de inteligência artificial.**

## RESUMO

Este artigo avalia o valor preditivo da modelagem multivariada nativa e de uma proxy térmica futura no TimesFM-3 aplicado à previsão pontual e probabilística da carga horária dos quatro subsistemas do Sistema Interligado Nacional. Foram utilizados dados horários completos do Operador Nacional do Sistema Elétrico entre maio de 2023 e agosto de 2026 e previsões de temperatura disponibilizadas pela Open-Meteo Previous Runs API, com valores em lead fixo emitidos antes de cada origem. A avaliação bloqueada compreendeu 85 origens semanais entre janeiro de 2025 e agosto de 2026. O horizonte primário foi de 168 horas; a previsão de 24 horas das segundas-feiras foi tratada como análise secundária. O experimento comparou configurações univariadas e multivariadas do TimesFM-3, com e sem temperatura futura, além de benchmarks sazonais, Ridge-ARX e LightGBM quantílico. As perdas foram agregadas por origem e avaliadas por MASE e sCRPS, com testes de Diebold-Mariano corrigidos, ajuste de Holm e bootstrap móvel em blocos. No horizonte semanal, a inclusão da proxy térmica futura reduziu a MASE em 6,96% e a sCRPS em 6,98% em relação à configuração que utilizava somente temperatura histórica e calendário, com intervalos de confiança de 95% inteiramente favoráveis. Em contraste, a comparação entre as configurações multivariada e univariada completas foi inconclusiva e não estabeleceu ganho nem equivalência. O TimesFM-3 completo também apresentou MASE inferior aos benchmarks executados, incluindo redução de 23,26% em relação ao Ridge-ARX. Os efeitos não foram confirmados no horizonte secundário de 24 horas. Conclui-se que, no desenho avaliado, o componente incremental identificado com precisão foi a informação térmica futura, e não a modelagem conjunta das cargas dos subsistemas.

**Palavras-chave:** previsão de carga; modelos fundacionais de séries temporais; TimesFM-3; previsão probabilística; temperatura; Sistema Interligado Nacional.

## ABSTRACT

This article evaluates the predictive value of native multivariate modeling and a future urban temperature proxy in TimesFM-3 for point and probabilistic forecasting of hourly electricity load across the four subsystems of Brazil's National Interconnected System. We use complete hourly load data from May 2023 to August 2026 and fixed-lead temperature forecasts obtained from the Open-Meteo Previous Runs API, with all implied issue times preceding the corresponding forecast origin. The blocked evaluation includes 85 weekly origins from January 2025 to August 2026. The primary horizon is 168 hours, while 24-hour forecasts covering Mondays only are treated as secondary. The experiment compares univariate and multivariate TimesFM-3 configurations, with and without future temperature information, against seasonal, Ridge-ARX, and quantile LightGBM benchmarks. Losses are aggregated at the forecast-origin level and evaluated using MASE and scaled CRPS, Harvey-Leybourne-Newbold-corrected Diebold-Mariano tests, Holm adjustment, and moving-block bootstrap inference. At the weekly horizon, adding the future temperature proxy reduced MASE by 6.96% and scaled CRPS by 6.98% relative to the configuration using calendar and historical temperature information only, with 95% confidence intervals entirely favoring the complete model. In contrast, the comparison between the complete multivariate and univariate configurations was inconclusive and established neither a multivariate gain nor equivalence. The complete TimesFM-3 configuration also achieved lower MASE than the executed benchmarks, including a 23.26% reduction relative to Ridge-ARX. These findings did not replicate at the secondary 24-hour horizon. The

evidence therefore identifies future temperature information, rather than joint cross-subsystem modeling, as the component associated with a precisely estimated predictive improvement.

**Keywords:** load forecasting; time-series foundation models; TimesFM-3; probabilistic forecasting; temperature; Brazilian power system.

## 1 INTRODUÇÃO

A previsão de carga elétrica transforma regularidades de consumo em informação operacional para programação, reserva, despacho e planejamento. O problema é particularmente relevante no Sistema Interligado Nacional (SIN), cuja dimensão territorial combina um calendário nacional compartilhado, subsistemas interdependentes e condições meteorológicas heterogêneas. Erros de previsão podem significar recursos alocados em excesso, maior exposição a desequilíbrios ou menor capacidade de antecipar picos e rampas. Ao mesmo tempo, a carga horária oferece um teste exigente para modelos generalistas: coexistem ciclos de 24 e 168 horas, feriados, tendência, mudanças de mensuração e respostas não lineares ao clima (Aquila et al., 2023; Hong e Fan, 2016).

Modelos fundacionais de séries temporais deslocam parte do esforço de ajuste local para o pré-treinamento em grandes coleções de séries. O TimesFM original demonstrou que um decodificador treinado em dados reais e sintéticos pode produzir previsões zero-shot competitivas em domínios e horizontes não vistos, sem estimação específica no conjunto de destino (Das et al., 2024). Em 31 de agosto de 2026, o Google Research anunciou o TimesFM-3, com 330.710.976 parâmetros no checkpoint avaliado, atenção entre variáveis, suporte nativo a covariáveis passadas e conhecidas no futuro e uma saída probabilística com nove quantis (Google Research, 2026a; Hugging Face, 2026). Essas propriedades tornam possível formular uma questão que versões predominantemente univariadas não respondiam diretamente: o compartilhamento de informação entre as cargas dos quatro subsistemas e a inclusão de meteorologia ex ante melhoram a previsão brasileira sem ajuste dos pesos?

A novidade arquitetural, porém, não constitui evidência de superioridade no SIN. Benchmarks energéticos recentes mostram que modelos fundacionais podem reduzir erro e esforço de treinamento, mas também registram forte heterogeneidade entre conjuntos, horizontes, calibração e restrições de hardware (Obermeier et al., 2026; Simeone, 2026; Za'ter e Hodge, 2026). Uma comparação válida exige ablações internas, baselines sazonais e modelos ajustados localmente. Exige, ainda, que a meteorologia futura represente informação disponível antes da origem da previsão. Utilizar o clima realizado no horizonte produziria vazamento e confundiria capacidade preditiva com acesso indevido ao futuro.

O caso brasileiro acrescenta uma mudança de definição. O ONS informa que a carga global passou a incorporar geração de usinas não supervisionadas em março de 2021 e, a partir de 29 de abril de 2023, uma estimativa da micro e minigeração distribuída. O segundo marco afeta diretamente a comparabilidade histórica e cria um canal adicional pelo qual a meteorologia pode relacionar-se à série publicada: além de influenciar o comportamento do consumo, ela participa da mensuração de parcela da carga global (ONS, 2026a). A amostra deste estudo começa em 1º de maio de 2023 para permanecer integralmente no regime mais recente.

**Questão de pesquisa.** Em origens semanais bloqueadas, iniciadas às segundas-feiras, a configuração zero-shot multivariada do TimesFM-3, combinada a calendário e proxies ex ante de temperatura a lead fixo, melhora as previsões pontuais e probabilísticas das cargas horárias dos quatro subsistemas do SIN quando

comparada ao modo univariado com a mesma informação, ao modo multivariado sem temperatura futura e a modelos executáveis no mesmo ambiente de CPU?

**Tese central.** A previsão conjunta das quatro cargas permite explorar fatores temporais compartilhados, enquanto o calendário e a temperatura a lead fixo acrescentam informação sobre o estado futuro. Em conjunto, esses canais devem reduzir perdas pontuais e probabilísticas, sobretudo no horizonte semanal e em regimes de pico, rampa ou temperatura elevada. A tese é refutável: ruído meteorológico, instabilidade das relações entre subsistemas e o caráter generalista do pré-treinamento podem produzir resultado inconclusivo ou desempenho inferior ao das ablações.

O horizonte confirmatório primário é o de 168 horas (H168-WEEK), composto por semanas não sobrepostas. O horizonte de 24 horas (H24-MON) é secundário e abrange somente as primeiras 24 horas das mesmas origens de segunda-feira; não representa um serviço diário com origens nos sete dias da semana. A unidade inferencial é a origem semanal pareada, e não cada célula subsistema-hora.

O artigo contribui em quatro dimensões. Primeiro, oferece avaliação independente do TimesFM-3 poucos dias após seu lançamento, usando commit e checkpoint congelados. Segundo, testa diretamente a informação multivariada e a meteorologia futura por ablações dentro do mesmo modelo. Terceiro, constrói um backtest ex ante com dados públicos do ONS e previsões meteorológicas a lead fixo, preservando a fronteira temporal de informação. Quarto, integra acurácia pontual, perdas probabilísticas, calibração, picos, rampas, heterogeneidade regional e custo computacional em hardware de consumo. Não se reivindica liderança geral: Chronos-2, TimesFM-2.5, Temporal Fusion Transformer e outros modelos contemporâneos não foram executados por restrição computacional.

## 2 REFERENCIAL TEÓRICO

### 2.1 Carga elétrica como processo temporal multiescala

A carga horária pode ser representada conceitualmente como a sobreposição de tendência, sazonalidade intradiária, sazonalidade semanal, calendário, clima e choques idiossincráticos. A decomposição não precisa ser aditiva no mecanismo real, mas explicita por que previsores que consideram apenas um componente podem falhar. O ciclo de 24 horas acompanha rotinas de residência, comércio, indústria e serviços; o ciclo de 168 horas combina hora e dia da semana; feriados e dias adjacentes modificam a atividade; e a tendência incorpora crescimento, eficiência, eletrificação e mudanças de composição econômica.

A temperatura é uma covariável central na literatura de curto prazo. Seu efeito tende a ser não linear, dependente do subsistema, da estação do ano e da difusão de equipamentos de refrigeração ou aquecimento. Um valor isolado tampouco representa integralmente o conforto térmico: umidade, radiação, precipitação e persistência também importam. Ainda assim, temperatura prevista e calendário aparecem repetidamente entre as entradas de modelos operacionais e acadêmicos, inclusive em aplicações ao sistema brasileiro (Aquila et al., 2023). Moraes et al. (2023) encontraram ganho preditivo ao combinar redes neurais e previsões climáticas em uma aplicação de grande escala no SE/CO, evidência que sustenta o mecanismo meteorológico, mas não antecipa o resultado de um modelo fundacional nem identifica causalidade.

No SIN, os alvos não são apenas quatro séries separadas. SE/CO, Sul, Nordeste e Norte compartilham calendário, choques macroeconômicos, hábitos de trabalho e sinais nacionais, mas apresentam climas, composições setoriais e níveis de carga distintos. Dependência contemporânea pode reduzir variância quando o modelo separa fatores comuns de variações específicas. O mesmo compartilhamento pode prejudicar a previsão quando correlações históricas se alteram ou quando a escala do SE/CO domina sinais dos subsistemas menores. Por isso, multivariação é uma hipótese empírica, não uma propriedade automaticamente benéfica.

## 2.2 Do ajuste local aos modelos fundacionais

Modelos estatísticos e de aprendizado de máquina usualmente estimam parâmetros com o histórico do próprio alvo. Essa adaptação pode capturar regularidades locais, mas exige desenho de atributos, seleção temporal, retreinamento e manutenção. Modelos fundacionais procuram aprender previamente um repertório amplo de padrões transferíveis. No uso zero-shot, os pesos permanecem fixos e o modelo recebe apenas o contexto da nova série, reduzindo o custo de treinamento local. O benefício potencial é maior quando há muitos alvos ou implantação rápida; o risco é que o prior aprendido não represente a estrutura do domínio de destino.

O TimesFM de primeira geração usa patches temporais e arquitetura decoder-only. A entrada é dividida em blocos, o que reduz o comprimento efetivo da sequência, e o modelo produz o horizonte sem ajuste específico no conjunto avaliado (Das et al., 2024). Essa formulação contribuiu para consolidar a comparação zero-shot, mas não resolvia de forma nativa toda a interação entre vários alvos e covariáveis.

O TimesFM-3 amplia o mecanismo. A documentação de lançamento descreve alternância entre atenção temporal causal e atenção entre variáveis. A atenção temporal preserva a direção do tempo; a atenção entre variáveis permite que cargas e covariáveis troquem informação em um mesmo período. Covariáveis conhecidas no futuro permanecem visíveis durante a previsão, enquanto os alvos futuros são mascarados. O horizonte é decodificado de forma não autorregressiva, e a saída contém uma previsão pontual e quantis de 0,1 a 0,9 (Google Research, 2026a; Google Research, 2026b).

Essas características produzem canais de ganho separáveis. A comparação entre o modo multivariado e o univariado, ambos com as mesmas covariáveis, estima o valor preditivo da informação cruzada. A comparação entre o modelo completo e uma configuração que recebe temperatura apenas no passado estima o valor incremental da proxy futura. Outras ablações informam o papel do calendário e o efeito conjunto da temperatura passada e futura. A arquitetura admite esses testes sem alteração de pesos, preservando a condição zero-shot.

## 2.3 Previsão probabilística e decisão sob incerteza

A previsão pontual resume apenas uma posição central. Duas distribuições podem compartilhar a mesma mediana e diferir substancialmente na probabilidade de erros grandes. Essa distinção é operacionalmente relevante em sistemas elétricos, nos quais a subestimação de picos e a incerteza de rampas podem exigir reservas distintas. Hong e Fan (2016) defendem a avaliação conjunta de acurácia, calibração e nitidez. Intervalos muito estreitos falham em cobertura; intervalos excessivamente largos podem cobrir bem sem oferecer informação útil.

Quantis permitem representar a distribuição condicional sem impor forma paramétrica. A perda pinball é própria para cada quantil e, quando agregada em uma grade de níveis, aproxima o escore probabilístico contínuo. Bracale et al. (2020) mostram a utilidade de regressão quantílica multivariada na previsão de carga. Neste estudo, a mediana ( $q=0,5$ ) é a previsão central comum; a perda probabilística média usa os nove quantis; e a cobertura e a largura do intervalo de 80% avaliam calibração e nitidez.

## 2.4 Hipóteses e condições de refutação

**H1 — valor da multivariação.** No horizonte confirmatório, T3-MF apresenta MASE e perda probabilística escalonada inferiores a T3-UF, que recebe exatamente as mesmas informações, mas prevê cada subsistema de forma independente.

**H2 — valor da temperatura futura.** No horizonte confirmatório, T3-MF apresenta MASE e perda probabilística escalonada inferiores a T3-MP, que recebe calendário no horizonte e temperatura somente no contexto passado.

O desempenho frente a SNaive-24, SNaive-168, Ridge-ARX e LightGBM quantílico é uma comparação externa secundária restrita ao conjunto efetivamente executado. T3-MF versus T3-MC mede o efeito composto de acrescentar temperatura passada e futura; T3-M0 versus T3-U0 examina a multivariação sem covariáveis. Resultado favorável somente em um subsistema, regime ou horizonte será descrito como heterogêneo, e não como confirmação universal.

## 3 METODOLOGIA

### 3.1 Desenho, período e unidade de análise

Foi realizado backtest temporal ex ante conforme o protocolo consolidado A4-TFM3-ONS-v1.2.0. As versões 1.0.0 e 1.1.0 foram preservadas com data, hora e SHA-256. Antes da abertura dos resultados confirmatórios, acrescentou-se a configuração T3-MP, idêntica a T3-MF quanto aos alvos, calendário, contexto, temperatura histórica, parâmetros e implementação, diferindo exclusivamente pela ausência da proxy de temperatura futura. O contraste confirmatório de H2 passou a ser T3-MF versus T3-MP. A base abrange 1º de maio de 2023 a 31 de agosto de 2026. Desenvolvimento e ajuste dos comparadores utilizam exclusivamente observações anteriores a 1º de janeiro de 2025; o teste bloqueado cobre 6 de janeiro de 2025 a 24 de agosto de 2026.

Foram fixadas 86 origens às segundas-feiras, 00h no horário de Brasília. Em cada origem, o contexto contém 8.064 horas — 48 semanas — de cada alvo. H168-WEEK prevê as 168 horas seguintes e forma semanas não sobrepostas. H24-MON prevê somente as 24 horas iniciais da mesma origem. O piloto de viabilidade inspecionou o realizado da última origem, 24 de agosto de 2026. Conforme decisão metodológica anterior à análise integral, essa origem foi preservada nos arquivos e apresentada separadamente, mas excluída da adjudicação confirmatória. A amostra principal contém, portanto, 85 origens, de 6 de janeiro de 2025 a 17 de agosto de 2026, equivalentes a 57.120 células subsistema-hora por modelo em 168 horas e 8.160 em 24 horas. Essas células são correlacionadas; testes e intervalos usam 85 perdas agregadas por origem. A versão com as 86 origens é uma sensibilidade transparente.

### 3.2 Dados de carga

A carga horária foi obtida no Portal de Dados Abertos do ONS, em arquivos anuais públicos (ONS, 2026b). Foram mantidos quatro subsistemas: SE/CO, Sul, Nordeste e Norte. O painel esperado e observado possui 117.024 linhas — 29.256 horas multiplicadas por quatro subsistemas —, sem duplicidades e sem ausência de carga. O período começa imediatamente depois da inclusão da MMGD no conceito publicado, evitando misturar o regime anterior no contexto de qualquer origem (ONS, 2026a).

Os arquivos brutos, o painel processado e os pesos do modelo foram preservados com tamanho, data de acesso e SHA-256. Os valores realizados gravados na tabela de previsões foram comparados novamente ao snapshot do ONS. O SIN total não foi incluído como quinto alvo, porque sua proximidade com a soma dos quatro componentes poderia criar vantagem multivariada mecânica.

### 3.3 Proxy meteorológica ex ante

A temperatura foi obtida na Open-Meteo Previous Runs API com o modelo explicitamente fixado em `gfs_seamless` (Open-Meteo, 2026). Para H24-MON, utilizou-se `temperature_2m_previous_day1`; para H168-WEEK, `temperature_2m_previous_day7`. Cada célula corresponde, respectivamente, a previsão produzida aproximadamente 24 ou 168 horas antes de seu horário válido. A construção é temporalmente anterior à origem para todos os passos, mas não representa um único ciclo do GFS: a trajetória combina valores de múltiplas execuções históricas em lead fixo.

Cada subsistema foi representado pela média simples de três pontos urbanos definidos antes dos resultados: São Paulo, Rio de Janeiro e Belo Horizonte para SE/CO; Curitiba, Porto Alegre e Florianópolis para Sul; Salvador, Fortaleza e Recife para Nordeste; e Manaus, Belém e Porto Velho para Norte. Trata-se de proxy macrorregional, sem ponderação populacional e sem pretensão de cobrir a heterogeneidade territorial completa.

A cobertura bruta no painel total foi 98,318% para `previous_day1` e 97,826% para `previous_day7`. Todas as falhas ocorreram entre dezembro de 2023 e janeiro de 2024. Como o primeiro contexto usado no teste começa depois desse intervalo, não houve valor ausente em nenhum contexto ou horizonte efetivamente avaliado. A regra congelada para eventual ausência foi interpolação apenas em lacunas internas de até três horas; lacunas restantes seriam preenchidas por climatologia de subsistema, mês e hora calculada antes de 2025. Na amostra empírica, a regra não precisou ser acionada.

### 3.4 Modelos e ablações

O objeto central é o TimesFM-3, pacote 3.0.1, checkpoint com 330.710.976 parâmetros e nove quantis. O repositório foi congelado no commit `aa480150652811e732d87a3c5344b235234104e3`, imediatamente posterior à correção que tratou alinhamento de covariáveis em contextos truncados, horizontes não múltiplos do patch e lotes mistos. O arquivo `model.safetensors` apresentou SHA-256 `a7592b0a8432baee54483254e5647856911ce69e09d09a9bb65904b2d98f17da`. Os pesos permaneceram fixos; não houve fine-tuning, LoRA ou atualização durante o teste. A licença não comercial permite pesquisa acadêmica, mas os pesos não integram o pacote de resultados (Hugging Face, 2026).

As configurações foram:

| Código | Alvos            | Calendário | Temperatura passada | Temperatura futura | Função                                      |
|--------|------------------|------------|---------------------|--------------------|---------------------------------------------|
| T3-U0  | um por consulta  | não        | não                 | não                | base univariada pura                        |
| T3-M0  | quatro conjuntos | não        | não                 | não                | multivariação sem covariáveis               |
| T3-MC  | quatro conjuntos | sim        | não                 | não                | valor do calendário                         |
| T3-MP  | quatro conjuntos | sim        | sim                 | não                | controle da temperatura futura              |
| T3-UF  | um por consulta  | sim        | sim                 | sim                | controle univariado com informação completa |
| T3-MF  | quatro conjuntos | sim        | sim                 | sim                | configuração central                        |

O calendário contém seno e cosseno da hora, seno e cosseno do dia da semana e indicador de feriado nacional. Quatro comparadores foram executados. SNaive-24 repete o valor de 24 horas antes; SNaive-168 repete o valor da semana anterior. Ridge-ARX combina lags de 168, 336, 504 e 672 horas, temperatura, calendário e tendência, com penalização escolhida somente no período anterior ao teste. LightGBM-Q estima nove regressões quantílicas globais com os mesmos atributos. Os quantis do LightGBM foram ordenados após a previsão.

Chronos-2, TimesFM-2.5, Temporal Fusion Transformer e outros modelos recentes não foram executados. A decisão preservou o contexto completo e todas as origens no ambiente de CPU, em vez de reduzir a amostra para ampliar o catálogo de modelos. Consequentemente, as comparações externas dizem respeito apenas ao melhor comparador entre os modelos efetivamente avaliados.

### 3.5 Métricas e inferência

A previsão pontual primária é o quantil 0,5 de cada modelo. A cabeça pontual nativa do TimesFM-3 foi mantida como robustez. O erro absoluto foi escalonado pelo erro absoluto médio de uma diferença sazonal de 168 horas, calculado separadamente por subsistema apenas na amostra pré-teste. A média dessas perdas é o MASE; valores menores são melhores, e a escala evita que o SE/CO domine apenas por possuir carga maior (Hyndman e Koehler, 2006).

A perda probabilística foi calculada como duas vezes a média das perdas pinball nos quantis 0,1 a 0,9 e escalonada pelo mesmo denominador sazonal. Foram reportados ainda MAE, RMSE, cobertura e largura do intervalo de 80%, erro de magnitude e horário do pico e máxima subestimação. Regimes extremos de carga, rampa e temperatura foram definidos pelo percentil 95 da amostra pré-teste, sem seleção posterior de eventos.

Para cada modelo, horizonte e métrica, as perdas foram agregadas sobre subsistemas e passos dentro da origem. Comparações confirmatórias usam as 85 diferenças semanais pareadas. Intervalos de 95% para a razão de perdas foram obtidos por bootstrap móvel com 10 mil reamostragens e blocos de quatro semanas; blocos de oito semanas constituem sensibilidade. Testes bilaterais de Diebold–Mariano usam variância HAC com quatro defasagens e correção de pequena amostra de Harvey–Leybourne–Newbold. Valores de  $p$  foram ajustados por Holm separadamente na família confirmatória de  $H_1$  e  $H_2$ , em cada métrica e horizonte. A inferência é preditiva, não causal (Diebold e Mariano, 1995).

A equivalência em H1 foi examinada formalmente por intervalo bilateral de 90% da razão de perdas, obtido com o mesmo bootstrap móvel pareado. A margem prática predefinida foi  $[0,99; 1,01]$ ; equivalência somente seria declarada se todo o intervalo permanecesse dentro dela (Lakens, 2017). Além das comparações pareadas, aplicou-se o Model Confidence Set de Hansen, Lunde e Nason (2011), ao nível de 10%, aos dez modelos. O procedimento sequencial utilizou a estatística  $T_{\max}$ , 10 mil reamostragens em blocos móveis de quatro origens e foi calculado separadamente para MASE e sCRPS em cada horizonte.

### 3.6 Validação técnica e reprodutibilidade

Os 14 testes oficiais do módulo de previsão foram executados sem falha. Um teste próprio reproduziu as condições críticas da correção incorporada ao commit: contexto de 15.361 pontos, horizonte de 168 horas, duas covariáveis passadas-futuras, três alvos em uma consulta e lote misto com outra consulta sem covariáveis. Foram verificadas formas  $(3, 168)$  para a previsão e  $(3, 168, 9)$  para quantis, alinhamento do primeiro e último passo futuro, ausência de valores não finitos e repetibilidade com tolerância de  $10^{-5}$ .

Todas as previsões foram persistidas antes da análise em arquivos separados por modelo e horizonte. A auditoria final exige dez modelos, 86 origens em cada horizonte, quatro subsistemas, leads completos, chaves únicas, valores finitos, quantis monotônicos depois da ordenação da biblioteca e coincidência exata do realizado com o snapshot do ONS. As métricas probabilísticas foram calculadas sobre os quantis retornados pela interface oficial, que aplica ordenação monotônica. Portanto, a taxa nula de cruzamentos caracteriza a saída operacional da biblioteca, não necessariamente os quantis brutos anteriores ao pós-processamento. O experimento foi executado em Fedora Linux, Python 3.14.7, PyTorch 2.14.0+cpu, sem GPU, com semente 413.


## 4 RESULTADOS

### 4.1 Integridade da execução e composição da amostra

A execução produziu exatamente 660.480 linhas de previsão: dez modelos multiplicados por quatro subsistemas, 86 origens e os dois horizontes de 24 e 168 horas. Todas as asserções de integridade foram satisfeitas. Não houve valor não finito, chave duplicada, origem ausente, lead incompleto ou divergência entre a carga realizada armazenada e o snapshot do ONS. Os nove quantis apresentaram ordenação monotônica na saída final da biblioteca. O teste específico do PR #483 passou para contexto de 15.361 horas, horizonte não múltiplo do patch, covariáveis passadas-futuras e lotes com covariáveis opcionais. A repetição produziu diferença máxima igual a zero tanto na previsão central quanto nos quantis.

A origem de 24 de agosto de 2026, examinada no piloto, responde por 96 linhas por modelo em H24-MON e 672 em H168-WEEK. Ela não integra nenhuma estatística confirmatória apresentada a seguir. Sua exclusão deixa 8.160 células por modelo no horizonte secundário e 57.120 no primário, totalizando 652.800 linhas modelo-subsistema-hora na amostra confirmatória. Esse total não é o tamanho inferencial: todos os testes usam  $N=85$  origens pareadas. A sensibilidade com as 86 origens preservadas manteve a direção e a interpretação dos contrastes centrais.

**Figura 1 — Desenho do backtest e horizontes avaliados.**



Fonte: elaboração integral por sistemas de inteligência artificial a partir do protocolo do estudo.

## 4.2 Desempenho agregado

A Tabela 2 apresenta as métricas da amostra confirmatória. Em H168-WEEK, T3-UF registrou o menor MASE por diferença mínima, 0,7175, enquanto T3-MF obteve 0,7176. A ordem se inverteu na perda probabilística: 0,5634 para T3-MF e 0,5638 para T3-UF. Essas diferenças são economicamente pequenas e não devem ser lidas como superioridade. A configuração T3-MP, sem temperatura futura, apresentou MASE de 0,7713 e sCRPS de 0,6057. Entre os comparadores ajustados ou sazonais, Ridge-ARX foi o melhor em MASE, com 0,9352.


Em H24-MON, a melhor configuração foi T3-UF, com MASE de 0,5213 e sCRPS de 0,4128. T3-MF apresentou 0,5292 e 0,4181, respectivamente. Todos os seis modos do TimesFM-3 ficaram abaixo de MASE 0,55, ao passo que Ridge-ARX registrou 0,9731, SNaive-168, 1,0670, LightGBM-Q, 1,6529, e SNaive-24, 2,8210. Como esse horizonte contém apenas segundas-feiras, a comparação não caracteriza um serviço diário geral.

**Tabela 2 — Métricas agregadas por horizonte na amostra confirmatória.**

| Modelo     | MASE 24 h | sCRPS 24 h | Cob. 80% 24 h | MASE 168 h | sCRPS 168 h | Cob. 80% 168 h |
|------------|-----------|------------|---------------|------------|-------------|----------------|
| T3-UF      | 0,5213    | 0,4128     | 80,71%        | 0,7175     | 0,5638      | 79,44%         |
| T3-MF      | 0,5292    | 0,4181     | 79,91%        | 0,7176     | 0,5634      | 80,90%         |
| T3-MP      | 0,5328    | 0,4220     | 81,73%        | 0,7713     | 0,6057      | 79,96%         |
| T3-MC      | 0,5392    | 0,4250     | 82,61%        | 0,7797     | 0,6110      | 80,20%         |
| T3-M0      | 0,5403    | 0,4276     | 81,63%        | 0,7832     | 0,6161      | 80,38%         |
| T3-U0      | 0,5408    | 0,4292     | 81,38%        | 0,7970     | 0,6267      | 79,64%         |
| Ridge-ARX  | 0,9731    | 0,7704     | 70,76%        | 0,9352     | 0,7444      | 74,07%         |
| SNaive-168 | 1,0670    | 0,8494     | 77,27%        | 1,0565     | 0,8434      | 77,45%         |
| LightGBM-Q | 1,6529    | 1,3642     | 39,11%        | 1,6443     | 1,3422      | 44,89%         |
| SNaive-24  | 2,8210    | 2,4823     | 40,31%        | 1,2540     | 1,0446      | 78,80%         |

Nota: N=85 origens pareadas. Cob. 80% é a cobertura empírica entre  $q_{0,1}$  e  $q_{0,9}$ . A mediana  $q_{0,5}$  é a previsão central comum.

**Figura 2 — MASE dos modelos nos dois horizontes.**



Fonte: resultados do backtest. A linha tracejada marca MASE=1.

### 4.3 Adjudicação das hipóteses

Na avaliação primária H168-WEEK, composta por 85 origens semanais entre 6 de janeiro de 2025 e 17 de agosto de 2026, a configuração completa multivariada do TimesFM-3 (T3-MF) apresentou MASE de 0,7176, sCRPS de 0,5634 e cobertura empírica de 80,90% para o intervalo nominal de 80%. Em comparação com T3-MP, que preservava o calendário e a temperatura histórica, mas omitia a proxy de temperatura futura, T3-MF reduziu a perda MASE em 6,96% — razão de perdas de 0,9304, intervalo de confiança de 95% por bootstrap móvel em blocos de 0,9053 a 0,9578 e  $p$  de Holm de 0,00000170 — e reduziu a sCRPS em 6,98% — razão de 0,9302, intervalo de 0,9043 a 0,9592 e  $p$  de Holm de 0,00000177. Os resultados apoiam H2 no horizonte semanal e permaneceram qualitativamente inalterados com o aumento do bloco de reamostragem de quatro para oito origens.

Em contraste, não foi encontrada evidência de ganho global da modelagem multivariada em relação ao TimesFM-3 univariado com o mesmo conjunto informacional. Na comparação entre T3-MF e T3-UF, a razão de perdas foi de 1,0001 para MASE, com intervalo de confiança de 95% de 0,9833 a 1,0158 e  $p$  de Holm de 0,987, e de 0,9993 para sCRPS, com intervalo de 0,9812 a 1,0177 e  $p$  de Holm de 0,939. Esses intervalos incluem tanto ganhos quanto perdas superiores à margem prática predefinida de 1%. H1 permanece, portanto, inconclusiva: os resultados não demonstram ganho multivariado global, mas também não estabelecem equivalência ou ausência de efeito.

**Tabela 3 — Contrastes confirmatórios no horizonte semanal.**

| Hipótese e métrica | Razão de perdas | Skill   | IC95% bloco 4    | IC95% bloco 8    | p-Holm    | Adjudicação  |
|--------------------|-----------------|---------|------------------|------------------|-----------|--------------|
| H1: MF/UF, MASE    | 1,0001          | -0,014% | [0,9833; 1,0158] | [0,9806; 1,0170] | 0,9873    | inconclusiva |
| H1: MF/UF, sCRPS   | 0,9993          | 0,075%  | [0,9812; 1,0177] | [0,9785; 1,0190] | 0,9388    | inconclusiva |
| H2: MF/MP, MASE    | 0,9304          | 6,962%  | [0,9053; 0,9578] | [0,9055; 0,9595] | 0,0000017 | apoiada      |
| H2: MF/MP, sCRPS   | 0,9302          | 6,983%  | [0,9043; 0,9592] | [0,9044; 0,9605] | 0,0000018 | apoiada      |

Fonte: perdas agregadas por origem; teste de Diebold–Mariano com HAC(4), correção HLN e ajuste de Holm.

O teste formal de equivalência confirmou essa classificação. Para MASE em H168-WEEK, o intervalo bilateral de 90% da razão T3-MF/T3-UF foi [0,9861; 1,0133] com bloco quatro e [0,9840; 1,0143] com bloco oito. Para sCRPS, os intervalos foram [0,9839; 1,0146] e [0,9819; 1,0159]. Nenhum ficou integralmente dentro da margem [0,99; 1,01]; portanto, a equivalência não foi demonstrada. Em H24-MON, os quatro intervalos de 90% também ultrapassaram a margem. Os resultados completos estão na tabela suplementar de equivalência.

O Model Confidence Set a 10% forneceu uma verificação conjunta. No horizonte semanal, apenas T3-MF e T3-UF permaneceram no conjunto superior tanto para MASE quanto para sCRPS; T3-MP foi eliminado antes da parada do procedimento. No horizonte de 24 horas, as seis configurações do TimesFM-3 permaneceram no conjunto superior em ambas as métricas, enquanto os quatro comparadores externos foram eliminados. Esse resultado reforça que o horizonte semanal distingue a contribuição da temperatura futura, mas não separa estatisticamente os modos completo multivariado e univariado.

No horizonte secundário H24-MON, restrito à previsão das 24 horas de segunda-feira a partir de origens semanais fixas, não houve replicação estatisticamente confirmatória de H1 ou H2. T3-UF apresentou numericamente a menor MASE, de 0,5213, seguido por T3-MF, com 0,5292, e T3-MP, com 0,5328. Entretanto, os intervalos das comparações incluíram a ausência de diferença, e os valores de  $p$  ajustados não permitiram rejeitar as hipóteses nulas. O ganho da proxy térmica futura deve, assim, ser descrito como específico do horizonte primário semanal, e não como resultado geral para todos os horizontes.

#### 4.4 Comparadores externos e ablações adicionais

Entre os benchmarks efetivamente executados no horizonte semanal, T3-MF apresentou MASE 23,26% inferior à do Ridge-ARX, 32,07% inferior à do sazonal ingênuo semanal e 56,36% inferior à do LightGBM quantílico. As três diferenças apresentaram intervalos de confiança inteiramente favoráveis ao TimesFM-3 e valores de  $p$  ajustados inferiores a 0,05. No sCRPS, as reduções correspondentes foram 24,31%, 33,20% e 58,02%. Em H24-MON, as reduções de MASE frente aos mesmos três comparadores foram 45,62%, 50,41% e 67,99%. Essa evidência demonstra o melhor desempenho entre os benchmarks executados neste estudo; não estabelece liderança sobre modelos fundacionais, arquiteturas profundas não avaliadas ou o estado da arte geral da previsão de carga.

A comparação exploratória entre T3-M0 e T3-U0 isolou multivariação sem covariáveis. No horizonte semanal, T3-M0 reduziu MASE em 1,72% e sCRPS em 1,69%, com intervalos abaixo de 1. Isso sugere que informação cruzada pode ajudar quando o conjunto informacional é austero. O ganho desaparece quando calendário e temperatura são oferecidos: o contraste confirmatório entre T3-MF e T3-UF fica centrado em zero. Uma interpretação possível é substituição informacional: covariáveis comuns absorvem parte do fator compartilhado entre as cargas. Essa leitura é compatível com o padrão, mas não identifica o mecanismo interno do modelo.


#### 4.5 Heterogeneidade por subsistema

A média global oculta diferenças regionais. Em H168-WEEK, as estimativas pontuais diferiram entre os subsistemas, favorecendo T3-MF no Norte (0,8512 contra 0,8670), Nordeste (0,8095 contra 0,8120) e SE/CO (0,5237 contra 0,5274), e T3-UF no Sul (0,6862 contra 0,6637). Essas diferenças são descritivas e

não constituem evidência inferencial de ganho específico por subsistema. Também descritivamente, a diferença entre T3-MF e T3-MP correspondeu a 2,94% no Norte, 1,98% no Nordeste, 9,41% no Sul e 16,22% no SE/CO. Esses percentuais não receberam testes pareados por origem nem correção confirmatória própria.

O SE/CO apresentou o menor erro escalonado entre os subsistemas, enquanto Norte e Nordeste permaneceram mais difíceis. A escala regional não explica sozinha esse padrão, pois o MASE normaliza cada carga por sua variação sazonal histórica. Composição econômica, qualidade da proxy térmica, amplitude de carga e estabilidade temporal são explicações concorrentes.

**Figura 3 — MASE por subsistema e configuração selecionada.**




Fonte: resultados do backtest; análises regionais são exploratórias.

#### 4.6 Calibração, extremos, picos e trajetória ilustrativa

A cobertura empírica do intervalo de 80% do T3-MF foi 80,90% em H168-WEEK e 79,91% em H24-MON, muito próxima do nível nominal. T3-UF apresentou 79,44% e 80,71%. O LightGBM-Q mostrou subcobertura acentuada, 44,89% e 39,11%, respectivamente. A largura semanal média do intervalo de T3-MF foi 1.978,77 MW, contra 1.929,00 MW no modo univariado e 2.239,96 MW no controle sem temperatura futura. Assim, a cobertura próxima do nominal não foi obtida apenas por intervalos indiscriminadamente mais largos.

**Figura 4 — Cobertura empírica dos intervalos de 80%.**




Fonte: resultados do backtest. A linha tracejada indica o nível nominal de 80%.

Nos regimes extremos semanais, T3-MF apresentou MASE 0,8884 em carga elevada, 0,6795 em rampas elevadas e 1,0877 em temperatura elevada. Descritivamente, os valores de T3-MP foram maiores nesses três recortes; em temperatura extrema, o controle sem informação térmica futura registrou 1,2401. Entretanto, T3-UF apresentou valor menor que T3-MF nesse mesmo regime, com MASE 1,0380. Sem testes pareados por origem e correção de multiplicidade próprios, esses recortes não constituem confirmação adicional de H1 ou H2.

O erro médio da magnitude do pico semanal foi 619,16 MW para T3-MF, 617,68 MW para T3-UF e 704,05 MW para T3-MP. O erro médio do horário do pico ficou entre 29,4 e 29,9 horas nos dois primeiros, revelando que prever a altura do pico é mais fácil que localizar seu momento ao longo de uma semana. A máxima subestimação média foi 1.422,12 MW em T3-MF, próxima dos 1.424,87 MW de T3-UF e inferior aos 1.538,62 MW de T3-MP.

A Figura 5 exibe uma origem escolhida por regra objetiva: a semana mediana segundo o erro do T3-MF, no SE/CO. Ela não representa o melhor caso. As duas configurações completas acompanham a sazonalidade intradiária e a transição para o fim de semana, enquanto o intervalo probabilístico se alarga nos vales e picos mais incertos.

**Figura 5 — Trajetória semanal ilustrativa no SE/CO.**



Fonte: origem mediana por MASE de T3-MF; seleção anterior à inspeção visual.

#### 4.7 Sensibilidade e custo computacional

A inclusão exploratória da origem do piloto não alterou a conclusão. Com 86 origens, o MASE semanal foi 0,7177 em T3-MF, 0,7173 em T3-UF e 0,7722 em T3-MP; os valores correspondentes de sCRPS foram 0,5631, 0,5633 e 0,6061. A mediana foi usada como previsão central comum. Na robustez com a cabeça pontual nativa, T3-MF manteve MAE de 631,83 MW e T3-UF, 629,53 MW, pois, no checkpoint empregado, a cabeça pontual coincidiu numericamente com a mediana nos modos avaliados.

O backtest integral consumiu 2 horas, 52 minutos e 49 segundos em oito núcleos de CPU, sem GPU, e atingiu pico de 3,85 GB de memória residente. As configurações completas dominaram o custo: T3-UF levou aproximadamente 39,9 minutos em 24 horas e 37,7 minutos em 168 horas; T3-MF, 16,6 e 16,8 minutos. O custo maior do modo univariado decorre de processar separadamente as quatro cargas. Esses tempos medem a implementação e o hardware utilizados, não uma comparação normalizada de eficiência entre arquiteturas.

## 5 DISCUSSÃO

### 5.1 Adjudicação da tese central

A tese central recebe apoio parcial e estruturalmente informativo. A parte que atribuíra ganho à temperatura futura foi confirmada no horizonte semanal: retirar apenas o segmento térmico futuro, mantendo quatro alvos, calendário e temperatura passada, aumentou as perdas em cerca de 7%. A parte que atribuíra ganho global à previsão conjunta das quatro cargas não foi confirmada sob informação completa. O modo multivariado e o univariado produziram perdas praticamente iguais, com intervalos compatíveis com pequenos ganhos ou pequenas perdas.

Esse resultado evita duas simplificações. A primeira seria declarar a tese integralmente confirmada porque T3-MF venceu modelos locais simples. Essa comparação não identifica o mecanismo multivariado nem o papel da temperatura futura. A segunda seria declarar a multivariação inútil porque H1 foi inconclusiva. O ganho de T3-M0 sobre T3-U0 no horizonte semanal e a heterogeneidade regional indicam que o compartilhamento de informação pode importar em condições específicas, embora não produza ganho agregado quando as covariáveis completas já estão presentes.

### 5.2 Valor informacional da temperatura prevista

O contraste MF-MP é particularmente forte porque altera somente a disponibilidade futura da temperatura dentro do mesmo checkpoint. A trajetória passada, o calendário, os quatro alvos, o contexto, as origens e os pesos permanecem idênticos. O ganho simultâneo em MASE e sCRPS indica melhoria tanto na localização central quanto na distribuição preditiva. A maior diferença no SE/CO e no Sul é compatível com respostas térmicas mais marcadas ou melhor representadas pelas cidades escolhidas, mas o desenho não permite identificar qual explicação predomina.

A falta de evidência em H24-MON não contradiz necessariamente o resultado semanal. Nas primeiras 24 horas, a carga possui forte persistência e a previsão térmica a lead fixo pode acrescentar pouco ao contexto recente. Ao longo de 168 horas, aumenta a distância em relação às observações de carga conhecidas e o calendário atravessa dias úteis e fim de semana; nesse cenário, informação térmica futura pode evitar que o modelo projete padrões históricos sob condições meteorológicas inadequadas. A interpretação permanece preditiva. Não se estima efeito causal da temperatura sobre a carga.

### 5.3 Multivariação, fatores comuns e heterogeneidade

O resultado nulo de H1 coloca um limite empírico na expectativa de que atenção entre variáveis gere ganho automático. As quatro cargas compartilham calendário e fatores nacionais, mas também têm escalas e composições diferentes. Quando calendário e temperatura estão disponíveis, parte da dependência comum pode ser redundante. Além disso, uma atenção treinada em domínio amplo não é obrigada a aprender as interações específicas do SIN.

O Sul fornece o sinal adverso mais visível: T3-UF supera T3-MF no MASE semanal, enquanto Norte, Nordeste e SE/CO apresentam diferenças descritivas na direção oposta. Agregar essas relações produz efeito próximo de zero. Isso sugere que futuras arquiteturas ou protocolos devem permitir pesos de

compartilhamento adaptativos e diagnóstico de transferência negativa. Também recomenda evitar escolher um único modo para todos os subsistemas apenas com base na média nacional.

#### 5.4 Relação com a literatura e com os comparadores

Os resultados corroboram a viabilidade zero-shot enfatizada por Das et al. (2024): sem ajuste dos pesos ao ONS, todas as configurações do TimesFM-3 superaram os comparadores locais executados nas métricas agregadas. Ao mesmo tempo, a heterogeneidade confirma a cautela dos benchmarks recentes de energia, nos quais o desempenho de modelos fundacionais varia por conjunto, horizonte e métrica (Obermeier et al., 2026; Simeone, 2026; Za'ter e Hodge, 2026).

O desempenho fraco do LightGBM-Q não deve ser interpretado como incapacidade geral de boosting. A implementação adotou uma especificação direta, global e congelada, com atributos limitados e sem extensa otimização por origem. Ridge-ARX foi o comparador mais competitivo, sobretudo no horizonte semanal, e ainda assim ficou 23,26% acima do MASE de T3-MF. A comparação mede o valor prático das configurações efetivamente executadas, não uma fronteira universal de métodos.

#### 5.5 Previsão probabilística e utilidade operacional potencial

A cobertura próxima de 80% constitui resultado relevante porque muitos ganhos pontuais podem ser acompanhados de intervalos mal calibrados. T3-MF combinou menor perda probabilística que T3-MP, cobertura nominal e intervalo mais estreito. O comportamento contrasta com a subcobertura do LightGBM-Q. Ainda assim, cobertura média não garante calibração condicional: subsistemas, leads e regimes podem esconder desvios que exigiriam recalibração antes de uso aplicado.

Os erros de pico também aconselham prudência. Uma diferença média de aproximadamente 620 MW na magnitude pode ser útil em planejamento, mas erros de tempo próximos de 29 horas no horizonte semanal limitam decisões sensíveis ao instante do máximo. O modelo deve ser entendido como gerador de cenários e referência preditiva, não como substituto automático de processos operacionais, conhecimento institucional ou previsão meteorológica de produção.

#### 5.6 Limitações do desenho

Este estudo possui limitações que restringem a generalização dos resultados. Primeiro, as origens foram fixadas semanalmente às segundas-feiras, de modo que a avaliação de 24 horas representa somente a carga das segundas-feiras e não o desempenho diário médio ao longo da semana. Segundo, a temperatura de cada subsistema foi aproximada pela média aritmética de três pontos urbanos selecionados ex ante, sem ponderação pela população, pela carga elétrica, pela área ou pela representatividade climática; essa variável deve ser interpretada como proxy térmica urbana macrorregional. Terceiro, os dados futuros foram obtidos em lead fixo por meio da Open-Meteo Previous Runs API: todos os horários implícitos de emissão precedem a origem, mas a trajetória futura combina valores produzidos em diferentes execuções e não corresponde a um único ciclo GFS arquivado na origem. Quarto, o conjunto de benchmarks não incluiu TimesFM-2.5, Chronos-2, Temporal Fusion Transformer ou outros modelos fundacionais e profundos, impedindo alegações de liderança geral. Quinto, a documentação pública do pré-treinamento do TimesFM-3 não permite excluir eventual sobreposição com séries brasileiras de energia. Finalmente, os quantis avaliados

incorporam a ordenação monotônica padrão da biblioteca, razão pela qual a ausência de cruzamentos não deve ser atribuída exclusivamente ao comportamento bruto do modelo.

Há limitações adicionais. Zero-shot significa ausência de ajuste local, não garantia de que o modelo nunca tenha visto dados relacionados. A definição de carga do ONS incorporou estimativa de MMDG em abril de 2023; o recorte evita misturar o regime anterior, mas não elimina revisões futuras. A proxy térmica não contém umidade, radiação ou precipitação. A origem do piloto foi excluída, reduzindo a amostra confirmatória para 85 semanas. O teste formal de equivalência também não estabeleceu equivalência dentro da margem prática predefinida.

## 6 CONCLUSÃO

Este estudo avaliou se a modelagem multivariada nativa e a inclusão de uma proxy térmica futura melhoram o desempenho do TimesFM-3 na previsão pontual e probabilística da carga horária dos quatro subsistemas do SIN. A estratégia empregou um backtest temporal bloqueado, com origens semanais, contexto comum de 8.064 horas, avaliação primária de 168 horas e comparação interna entre configurações que diferiam apenas quanto à estrutura multivariada ou à presença da informação térmica futura.

Os achados não confirmam a tese central em sua formulação conjunta. O componente para o qual se obteve evidência precisa foi a informação térmica futura. Em H168-WEEK, sua inclusão reduziu em aproximadamente 7% tanto a perda pontual quanto a probabilística, com resultados robustos à alteração do tamanho dos blocos de reamostragem. Em contrapartida, a configuração multivariada completa apresentou desempenho agregado praticamente idêntico ao da configuração univariada completa, mas os intervalos de confiança não foram suficientemente estreitos para estabelecer equivalência. A inferência correta é, portanto, de ausência de evidência de ganho multivariado global, e não de demonstração de que o componente multivariado seja irrelevante.

A heterogeneidade descritiva entre os subsistemas reforça essa cautela. As estimativas pontuais favoreceram a configuração multivariada no Norte, Nordeste e Sudeste/Centro-Oeste, enquanto o Sul favoreceu a configuração univariada. Sem testes de subgrupo ajustados para multiplicidade, esses padrões não permitem afirmar a existência de ganhos específicos por subsistema. De modo semelhante, os resultados em períodos de temperatura extrema e nas métricas de pico devem ser interpretados como análises secundárias, e não como novas confirmações das hipóteses principais.

No conjunto restrito de benchmarks executados, o TimesFM-3 completo apresentou vantagem expressiva no horizonte semanal, superando o Ridge-ARX, os referenciais sazonais e o LightGBM quantílico na MASE. Essa comparação demonstra que o modelo foi competitivo nas condições avaliadas, mas não permite concluir que seja superior a outros modelos fundacionais ou ao estado da arte, pois TimesFM-2.5, Chronos-2, TFT e outras arquiteturas profundas não integraram o experimento.

Os resultados do horizonte secundário de 24 horas não reproduziram o ganho térmico ou multivariado. Como esse horizonte contém somente segundas-feiras, ele não constitui uma avaliação diária representativa de toda a semana. A validade externa do resultado favorável deve, portanto, permanecer restrita ao horizonte semanal e ao período de teste considerado.

Em síntese, o experimento mostra que previsões térmicas disponíveis antes da origem podem fornecer informação incremental relevante ao TimesFM-3 para a previsão semanal da carga brasileira. Ao

mesmo tempo, não fornece evidência de que a modelagem conjunta das quatro cargas produza, por si só, melhora agregada detectável. O estudo contribui ao separar empiricamente o valor do conjunto informacional do valor da arquitetura multivariada e ao preservar resultados inconclusivos e adversos, evitando atribuir automaticamente o desempenho de um modelo fundacional a todos os recursos incorporados à sua arquitetura.

### **Contribuições**

O artigo oferece cinco contribuições. Primeiro, apresenta uma avaliação independente e temporalmente bloqueada do TimesFM-3 aplicada às quatro cargas do SIN, com pesos, commit, semente e hashes congelados. Segundo, separa por ablação o papel da temperatura futura e da previsão conjunta, evitando inferir mecanismos a partir de uma tabela de ranking. Terceiro, demonstra uma estratégia reprodutível para construir proxies ex ante a lead fixo com dados públicos, explicitando que elas não equivalem a um vintage meteorológico operacional. Quarto, utiliza origem semanal como unidade inferencial, com dependência temporal, multiplicidade e exposição do piloto tratadas de forma explícita. Quinto, integra métricas pontuais, probabilísticas, regionais, de extremos, picos e custo computacional, sem ocultar resultados nulos ou adversos.

### **Estudos futuros**

Estudos futuros devem reconstruir vintages meteorológicos completos por ciclo de inicialização e comparar a proxy urbana com agregações ponderadas por carga, população e área. Também devem ampliar as origens de 24 horas para todos os dias da semana, testar janelas sazonais mais longas e verificar estabilidade sob revisões do ONS. A comparação de modelos deve incluir TimesFM-2.5, Chronos-2, TFT e outros modelos fundacionais e especializados sob orçamento computacional normalizado.

Outra linha promissora é estimar estratégias híbridas por subsistema: seleção ex ante entre modo multivariado e univariado, atenção com compartilhamento regularizado ou ensembles que reduzam transferência negativa no Sul. Recalibração temporal dos quantis, perdas assimétricas para subestimação, avaliação de rampas compostas e simulações de impacto econômico aproximariam o estudo de decisões do setor elétrico. Por fim, auditorias do corpus de pré-treinamento e testes em períodos inteiramente posteriores ao lançamento são necessários para avaliar contaminação, deriva e verdadeira generalização temporal.

### **Síntese final**

No horizonte semanal de 168 horas, a informação térmica futura reduziu em aproximadamente 7% as perdas pontual e probabilística do TimesFM-3, mas a modelagem multivariada das quatro cargas não produziu ganho global estatisticamente identificável em relação à configuração univariada com as mesmas covariáveis; essa comparação permaneceu inconclusiva e não demonstrou equivalência.

### **DECLARAÇÃO DE AUTORIA E PRODUÇÃO POR INTELIGÊNCIA ARTIFICIAL**

Não há autor humano declarado. A questão de pesquisa, o referencial teórico, as hipóteses, o protocolo metodológico, a aquisição e o tratamento automatizado dos dados, a programação, a execução dos modelos, os testes estatísticos, a geração de tabelas e figuras, a interpretação dos resultados, a redação e a compilação do estudo foram realizadas integralmente por sistemas de inteligência artificial. A participação

humana limitou-se à formulação da solicitação, ao fornecimento da infraestrutura computacional e à transmissão de instruções e artefatos entre os sistemas. Nenhuma pessoa humana é apresentada como autora, programadora, analista, executora ou responsável pela interpretação científica. Os sistemas, versões, prompts, códigos, logs, dados, hashes e artefatos utilizados estão identificados no manifesto de proveniência.

O modelo Pro disponível na interface web do ChatGPT atuou como planejador teórico, orquestrador e autoridade final sobre as decisões científicas. O Codex executou localmente a aquisição e auditoria de dados, a programação, as estimações, os testes, as figuras e a compilação dos artefatos.

Sistemas de inteligência artificial não possuem personalidade jurídica e não podem assumir responsabilidade editorial, declarar conflitos em nome próprio ou celebrar contratos de publicação. O manuscrito somente deve ser submetido a repositório ou periódico que aceite explicitamente essa forma factual de atribuição. Nenhum nome humano foi incluído para contornar requisitos editoriais.

## DISPONIBILIDADE DE DADOS, CÓDIGO E MATERIAIS

Os dados de carga são públicos e foram obtidos no Portal de Dados Abertos do ONS. As proxies térmicas foram obtidas pela Open-Meteo Previous Runs API. Código, protocolos, manifestos, hashes, tabelas agregadas, figuras e instruções de replicação podem ser disponibilizados com o artigo. Os pesos do TimesFM-3 não são redistribuídos; devem ser obtidos da fonte oficial e usados sob sua licença. O snapshot de pesquisa foi finalizado com cobertura integral das alegações e sem lacunas de evidência registradas.

## ASPECTOS ÉTICOS E CONFLITOS

O estudo utiliza exclusivamente dados públicos agregados, sem seres humanos identificáveis, animais ou intervenção experimental. Não há financiamento declarado nem conflito de interesses humano a atribuir. As limitações de responsabilidade decorrentes da autoria integral por sistemas de inteligência artificial são explicitadas na declaração anterior.

## REFERÊNCIAS

- AQUILA, G.; MORAIS, L. B. S.; DE FARIA, V. A. D.; LIMA, J. W. M.; LIMA, L. M. M.; DE QUEIROZ, A. R. An overview of short-term load forecasting for electricity systems operational planning: machine learning methods and the Brazilian experience. *Energies*, v. 16, n. 21, art. 7444, 2023. DOI: 10.3390/en16217444.
- BRACALE, A.; CARAMIA, P.; DE FALCO, P.; HONG, T. Multivariate quantile regression for short-term probabilistic load forecasting. *IEEE Transactions on Power Systems*, v. 35, n. 1, p. 628–638, 2020. DOI: 10.1109/TPWRS.2019.2924224.
- DAS, A.; KONG, W.; SEN, R.; ZHOU, Y. A decoder-only foundation model for time-series forecasting. *Proceedings of the 41st International Conference on Machine Learning*, 2024. arXiv:2310.10688.
- DIEBOLD, F. X.; MARIANO, R. S. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, v. 13, n. 3, p. 253–263, 1995. DOI: 10.1080/07350015.1995.10524599.
- GOOGLE RESEARCH. TimesFM-3: a zero-shot foundation model for multivariate forecasting. 31 ago. 2026. Disponível em: <https://research.google/blog/timesfm-3-a-zero-shot-foundation-model-for-multivariate-forecasting/>. Acesso em: 3 set. 2026.
- GOOGLE RESEARCH. TimesFM: time series foundation model for forecasting. Repositório GitHub, commit aa480150652811e732d87a3c5344b235234104e3. 2026. Disponível em: <https://github.com/google-research/timesfm>. Acesso em: 3 set. 2026.
- HANSEN, P. R.; LUNDE, A.; NASON, J. M. The model confidence set. *Econometrica*, v. 79, n. 2, p. 453–497, 2011. DOI: 10.3982/ECTA5771.

- HONG, T.; FAN, S. Probabilistic electric load forecasting: a tutorial review. *International Journal of Forecasting*, v. 32, n. 3, p. 914–938, 2016. DOI: 10.1016/j.ijforecast.2015.11.011.
- HUGGING FACE. Google TimesFM 3.0 PyTorch: model card and checkpoint. 2026. Disponível em: <https://huggingface.co/google/timesfm-3.0-pytorch>. Acesso em: 3 set. 2026.
- HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. *International Journal of Forecasting*, v. 22, n. 4, p. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.
- LAKENS, D. Equivalence tests: a practical primer for t tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, v. 8, n. 4, p. 355–362, 2017. DOI: 10.1177/1948550617697177.
- MORAIS, L. B. S.; AQUILA, G.; DE FARIA, V. A. D.; LIMA, L. M. M.; LIMA, J. W. M.; DE QUEIROZ, A. R. Short-term load forecasting using neural networks and global climate models: an application to a large-scale electrical power system. *Applied Energy*, v. 348, art. 121439, 2023. DOI: 10.1016/j.apenergy.2023.121439.
- OBERMEIER, M.; PRUCKNER, M.; HASELBECK, F.; ZEISELMAIR, A. FETS benchmark: foundation models enable scalable and generalizable energy time series forecasting. *Energy and AI*, v. 26, art. 100867, 2026. DOI: 10.1016/j.egyai.2026.100867.
- ONS — OPERADOR NACIONAL DO SISTEMA ELÉTRICO. Carga e geração. 2026. Disponível em: <https://www.ons.org.br/paginas/energia-agora/carga-e-geracao/>. Acesso em: 3 set. 2026.
- ONS — OPERADOR NACIONAL DO SISTEMA ELÉTRICO. Curva de carga horária. Portal de Dados Abertos. 2026. Disponível em: <https://dados.ons.org.br/dataset/curva-carga>. Acesso em: 3 set. 2026.
- OPEN-METEO. Previous Runs API: historical forecast data at fixed lead-time offsets. 2026. Disponível em: <https://open-meteo.com/en/docs/previous-runs-api>. Acesso em: 3 set. 2026.
- SIMEONE, L. Time series foundation models for energy load forecasting on consumer hardware: a multi-dimensional zero-shot benchmark. arXiv:2602.10848, 2026.
- ZA'TER, M. E.; HODGE, B.-M. Empirical assessment of time-series foundation models for power system forecasting applications. arXiv:2604.22077, 2026.